

AI & Linked Data

Verwantschap, verschil en samenspel

College 4 — GMB Opleiding 2026

Dag 1 · 2 juni 2026 · Martijn de Riet · bimforce

Waarom dit college?

- AI is nu **overall in het gesprek** — maar zelden helder uitgelegd
- Linked Data klinkt **abstract** — maar is concreter dan je denkt
- De twee worden vaak **tegen elkaar gezet** — terwijl ze elkaar versterken
- Voor GMB telt: **welke beslissingen neem je nu**, wetende dat AI snel verandert?

Doel: aan het eind heb je een eerlijk beeld — voorbij de hype en gebakken lucht — van wat AI voor informatiebeheer betekent en waar de grenzen liggen.

Deel A: Wat is Linked Data?

Linked Data: bijna 20 jaar oud

Tim Berners-Lee — bedenker van het World Wide Web — formuleerde in **2006** de vier principes:

1. Gebruik **unieke namen (URIs)** voor dingen
2. Maak die URIs **opvraagbaar via HTTP** — zelfde mechanisme als het web
3. Lever **bruikbare informatie** bij elke URI (RDF, SPARQL)
4. **Link naar andere dingen** via hun URIs

Wat het web deed voor documenten — alles opvraagbaar via hyperlinks — kan Linked Data doen voor **data**.

De bouwsteen: een triple

Subject

het ding
"Mijn gebouw"

Predicate

de relatie
"heeft bouwlagen"

Object

waarde of ander ding
"3"

Voorbeelden:

mijngebouw

:heeftBouwlagen

3

mijngebouw

:heeftWaarde

1250000

mijngebouw

:ligtIn

:nederland

Een graph = verzameling triples. Bevragen via **SPARQL** (analoog aan SQL voor tabellen).



"En Linked Open Data?"

— Opnieuw Tim Berners-Lee:

*"Linked Data die zodanig gelicenseerd en ontsloten is
dat de inhoud gratis beschikbaar is
voor gebruikers."*

Verschillende stadia

*Linked Data die zodanig
gelicenseerd en ontsloten is dat
de inhoud gratis beschikbaar is
voor gebruikers.*

— Tim Berners-Lee


Het **5-sterren schema** beschrijft de
gradaties — van losse PDF tot
volledig gelinkte open data:



Legenda · OL = Open License · RE = Re-usable · OF = Open Format · URI = URI-bare ·
LD = Linked Data


5-star scheme · Tim Berners-Lee

Linked Open Data in 2014




By Max Schmachtenberg, Christian Bizer, Anja Jentzsch and Richard Cyganiak · lod-cloud.net · CC BY-SA 3.0

Linked Open Data in 2017



Linked Open Data in 2024



By John P. McCrae · lod-cloud.net · CC BY 4.0

Van tabel naar graph

Dezelfde data, drie manieren om ze vast te leggen — van impliciet naar expliciet.

Klassieke DB · tabellen + JOIN

gebouwen

id	naam	bouwlagen	waarde	locatie_id
1	mijngebouw	3	1250000	7

locaties

id	naam	land
7	Locatie-12	NL

JOIN-query (samenstelling)

```
SELECT * FROM gebouwen g
JOIN locaties l ON g.locatie_id = l.id
```

triple-vorm



Triples · S · P · O


Subject	Predicate	Object
mijngebouw	bouwlagen	3
mijngebouw	waarde	1250000
mijngebouw	ligtIn	NL



voeg pijlen toe

Graph · knopen + relaties

Linked Data in één plaatje



Elk **ding** = knoop met unieke ID

Elke **relatie** = benoemde lijn met betekenis

Elk veld draagt context

Alles **navigeerbaar**: van pompput naar norm naar geldigheidsdatum

Linked Data = **data met expliciete relaties** die voor mens én machine te volgen zijn.

Hoe verhoudt LD zich tot wat je kent?

Systeem	Wat slaat het op?	Waar het tegen aanloopt
Spreadsheet	rijen × kolommen	relaties buiten dezelfde rij
SQL-database	tabellen + joins	flexibel relaties toevoegen zonder schema-wijziging
Documentdatabase	losse documenten met velden	relaties tussen documenten
Graph / Linked Data	knopen + relaties als eerste-klas	klassieke tabel-analyse minder snel

LD blinkt uit als "**welke X is verbonden met welke Y via Z?**" de centrale vraag is. Dat is in beheer + projectoverdracht vrijwel altijd het geval.

Praktijkvoorbeelden — bestaande ontologieën

Linked Data is in productie — vandaag staan duizenden gepubliceerde ontologieën klaar. Voor de bouw + infra-sector een greep:

Waternet W-OTL

Domein: riolering, drinkwater, dijken, vaarwegen — pionier in NL-watersector. Viewer: otl.waternet.nl/viewerv2/v1f

Aquo-standaard

Domein: water-sector NL — termen + objecttypen, beheerd door IHW. Viewer/wiki: [aquo.nl](https://www.aquo.nl)

ETIM via bSDD

Domein: technische installatie-producten (pompen, kleppen, schakelmateriaal). 30.000+ klassen. Direct relevant voor E&I op RWZI.

NMD (Nationale Milieudatabase)

Domein: **LCA + CO₂ + materialen**. Sinds 2024 koppeling met NL-SfB en ETIM via bSDD. Voor duurzaamheids-rapportages. [milieudatabase.nl](https://www.milieudatabase.nl)

IFC class library via bSDD

Domein: gebouwde omgeving algemeen. De IFC-classes (IfcWall, IfcPump, IfcBuildingStorey) zijn als ontologie in bSDD opvraagbaar. Basis voor 90% van de BIM-tools.

De centrale bSDD-viewer: search.bsdd.buildingsmart.org — meer dan 350 gepubliceerde dictionaries doorzoekbaar. Per klasse: definitie, eigenschappen, koppelingen naar andere ontologieën.

Valkuilen bij OTL-werk

Voor wie zelf met OTL/ontologie aan de slag gaat — vier veelgemaakte fouten:

1. OTL is nooit "af"

Een ontologie groeit met je domein-inzicht. Wachten op "100% compleet" = nooit beginnen. Plan voor doorlopende iteratie.

2. Werk met de 80-20 regel

De enige goede test is de praktijk. Bouw 80% snel + valideer op échte data; los de laatste 20% op naarmate edge-cases zich melden.

3. Begin met wat je hebt — destilleer

Gebruik bestaande data om een basis-OTL te genereren. Vraag: "wat zit er nu al in onze data, en hoe expliciet maken we dat?"


4. Valideer met wat je hebt

BIM-modellen, MJOP-data, vergunningen, P&ID's — die zitten in jullie systemen. Analyseer, destilleer, en gebruik die datasets om je OTL minstens te valideren.


De rode draad: een OTL ontstaat door doen — itereren op wat je hebt. Wie wacht tot het schema perfect is, levert nooit. Wie begint met wat hij heeft + leert per iteratie, bouwt over twee jaar iets dat *werkt*.

Deel B: Wat is AI eigenlijk?

AI in één plaatje (zonder wiskunde)




1. Geef het model **veel** voorbeelden
2. Het leert **patronen** uit die voorbeelden
3. Bij nieuwe input geeft het de **meest waarschijnlijke** uitkomst
4. Dat is alles — pure patroonherkenning, los van begrip of redeneren




Een AI-model *weet* niks. Het herkent patronen die statistisch vaak voorkwamen in trainingsdata. Heel goed in herkennen, slecht in *begrijpen waarom*.

Een digitale Pavlov-reactie op grote schaal

1 · juist → beloning



2 · fout → bijstelling



3 · x miljarden keren



Implicatie: Honderden miljoenen tot miljarden "knoppen" zijn na de training afgesteld. Niemand kan zeggen *welke knop waarvoor staat* — daarom **black box**. Als het model antwoord geeft, blijft het waarom achter de schermen — onverifieerbaar.

Waar AI hierdoor sterk in is

- **Grote hoeveelheden data analyseren** —
patronen vinden in duizenden modellen, documenten, scans
- **BIM Protocol → Uitvoeringsplan** vertalen —
gestructureerd document genereren uit eisen-tekst
- **ILS analyseren en omzetten naar IDS** —
informatie-leveringsspecificaties machine-leesbaar maken
- **bSDD automatisch toepassen op een model** —
concepten herkennen en aan de juiste classificatie koppelen
- **Onverwachte overeenkomsten vinden** —
bv. tussen normbladen, contracten en bestaande beheer-data

Patroon: alles waar grote volumes data en herkenbare structuren samenkomen. Repetitief, schaalbaar, waar fouten op detail aanvaardbaar zijn omdat ze in het proces worden afgevangen.

Waar AI tegen grenzen aanloopt

- **Bewijzen dat een ontwerp constructief veilig is** —
patroon-match $\neq$ berekening met aansprakelijkheid
- **Bewijzen dat een liftkeuring op tijd is uitgevoerd** —
een feit checken vraagt deterministische lookup
- **Verklaren wáárom een keuze de juiste is** —
alleen pattern-output zonder reconstrueerbaar redeneer-proces
- **Garanderen dat een uitkomst altijd klopt** —
statistische voorspelling met variabele uitkomst
- **Aansprakelijkheid dragen** —
tekenbevoegdheid en verzekering liggen bij rechtspersonen — mensen, organisaties
- **Werken in echt nieuwe situaties** —
buiten trainingsdata gokt het model (zonder dat te signaleren)

Patroon: alles waar je aantoonbaarheid, traceerbaarheid of aansprakelijkheid nodig hebt. Veiligheid, contracten, audits, vergunningen. AI biedt statistische waarschijnlijkheden — contractuele zekerheid

AI als gateway

- AI **vertaalt natuurlijke taal** naar query's, code, transformaties
- Tabellen, JSON, IFC, SPARQL — voor de gebruiker één conversatie
- Direct bruikbaar zonder Python-cursus, JOIN-syntax of schema-kennis vooraf
- **De drempel valt weg:** data-processing-superpowers binnen handbereik

AI is de **interface** die structuur bereikbaar maakt voor mensen zonder data-engineering-achtergrond — een laag bovenop bestaande data-architectuur.
Maar je moet het wel valideren.

Deel C: Het samenspel

Garbage in, garbage out — voor beide

Een AI is zo goed als de data waarop hij is getraind. **Dezelfde wet** geldt voor LD: foute verbanden = foute conclusies.

Inconsistent

Soms "*pompput*", soms "*PP*",
soms "*vuilwaterpomp*"

Incompleet

Helft van de assets
ongeclassificeerd

Tegenstrijdig

Spreadsheet zegt A, model zegt B

De opkomst van AI maakt informatie-hygiëne belangrijker. Slechte data wordt door AI **versterkt** — fouten worden geamplificeerd over de hele output.

Wat is een LLM eigenlijk?

Een enorme KnowledgeGraph.

Honderden miljarden tot biljoenen impliciete triples — relaties tussen woorden, concepten, feiten.

Je vraag "*hoeveel verdiepingen heeft dit gebouw?*" wordt onder water omgezet naar zoiets:


?ditgebouw :heeftVerdiepingen ?aantal .

Verschil met "echte" LD: deze triples zijn statistisch afgeleid uit het pre-training corpus. Hetzelfde principe — andere herkomst. Effectief; audit-spoor ontbreekt.

Het samenspel: LD + AI = RAG

Zonder LD

- Veel "redelijk klinkende" antwoorden
- Bron-traceerbaarheid beperkt
- **Hallucinaties:** gefabriceerde feiten zonder bron



Met LD als context


- Antwoorden volgen expliciete relaties
- Traceerbaar naar bron-knopen
- Veel minder hallucinaties



RAG: Retrieval-Augmented Generation. AI gebruikt zijn eigen KnowledgeGraph als bron van waarheid, structuur voor reasoning en "template" voor het antwoord ineen.


Waarom RAG?

1 · Vanuit training




Patroon trainingsdata: $2 + 2 = 4$

2 · Context vervuild



genoeg ruis → twijfel over de basis

3 · RAG met LD-graph




Externe waarheid checkt elk antwoord

Een LLM werkt op **patronen**; interne *waarheid* ontbreekt. RAG legt expliciete waarheid náást het patroon: alleen wat klopt met de graph mag erdoor. Andersom geldt het ook — een vervuilde sensor levert hetzelfde probleem op: pattern-match-in, pattern-match-uit, óók als de input ruis bevat.

Beide draaien om verbanden

AI vindt verbanden in data. LD legt verbanden expliciet vast. **RAG** = AI volgt het pad dat LD afdwingt.

1 · AI kiest enkel statistisch




"Meest waarschijnlijk" — statistisch passend, los van feitelijke juistheid

2 · LD dwingt het juiste pad af



Regels bepalen hoofdroute

3 · RAG — AI volgt LD's pad



AI kiest meest waarschijnlijke goede route

AI is goed in **vinden** van verbanden. LD is goed in **vastleggen** van verbanden die er moeten zijn voor audit, beheer, hergebruik. RAG verbindt die twee: AI volgt routes die LD als geldig kent — gestuurde keuze door expliciete graph-feiten.

Het cruciale verschil

AI = black box

Model zegt: "deze lift is een goederenlift"

→ **Waarom?** Omdat hij eruitziet als een goederenlift en daar heeft iemand getypt "goederenlift 2".

In bouw: bij wettelijke aansprakelijkheid onvoldoende.

LD = auditeerbaar

Graph zegt: "Deze lift is via *T-cluster regime-bepaling* (NL-SfB 66.11 + *bediening_locatie*) een **personenlift** volgens *Wwbl § 1a + NEN-EN 81-20:2020*"

→ **Volledig traceerbaar.**

In bouw: contracteerbaar bewijs.

Juridische lakmoesproef: kun je in een geschil aantonen hoe een conclusie tot stand kwam?

Bij alleen AI: nee.

Met ondersteuning van LD: ja.

Praktijkvoorbeeld 1 — Documentherkenning op Den Bosch

Vraag (van beheer-tak): "Welke documenten in ons archief horen bij de zandfilter-pompen van RWZI Den Bosch en verwijzen naar NEN-3140?"

AI alleen

Doorzoekt alle pdf's in projectarchief. Vindt 47 "treffers" op NEN-3140. Sommige horen bij Dinther, sommige bij Aarle-Rixtel, paar bij Den Bosch — alles op één hoop. Handmatig filteren = uren.


LD + AI

Graph kent RWZI Den Bosch → zandfilter → pompen → toepasselijke normen. AI haalt alléén documenten op die in dit pad voorkomen + vat ze samen. **14 relevante hits**, met bron-traceerbaarheid.

Praktijkvoorbeeld 2 — Data uit een onbekende OTL ontsluiten

Vraag: "Hoeveel onderhoud heeft type pompput X — wat zegt Waternet's W-OTL daarover?" Iemand bij GMB zonder W-OTL-kennis. Hoe los je dat op via Linked Data?

1. **Aquo-termen** in eigen project
2. **bSDD-koppeling** naar W-OTL
3. **W-OTL bevragen** via otl.waternet.nl
4. **Antwoord retour:** onderhouds-frequentie
5. **GMB hergebruikt ritmiek** zonder W-OTL te leren



Zonder W-OTL-kennis: één query haalt 'm op.

Het resultaat — één triple, alles erin

De volledige vraag — "wat is de onderhouds-frequentie van deze pompput?" — komt neer op één Linked Data triple:

`aquo:pompput-X` `wotl:inspectieFrequentie` **"P2Y"**

elke **2 jaar** inspectie volgens Waternet's W-OTL — voor pompputten van dit type

`aquo:` → <https://www.aquo.nl/dictionary/v1/>

`wotl:` → <https://otl.waternet.nl/dictionary/v1/>

`"P2Y"` → ISO 8601 duration: 2 jaar

Subject + Predicate + Object. Drie identifiers, één feit, allemaal publiek. **Aquo was de wayfinder** — het einddoel is de W-OTL-frequentie.

Praktijkvoorbeeld 3 — AI-chat over Den Bosch

Een teamleider realisatie stelt vragen aan een chat-interface die **alleen Den Bosch-projectdata** kent:

"Welke wijzigingen op de doseerinstallatie zijn na inbedrijfname doorgevoerd en wie heeft die goedgekeurd?"

→ Wijzigingsnotities + alliance-besluiten + goedkeurings-mails, gekoppeld via de graph.

"Welke pompen op Den Bosch zijn vervangen vergeleken met het ontwerp van Aarle-Rixtel?"

→ Vergelijking ontwerp-graph Aarle-Rixtel ↔ as-built Den Bosch — AI levert verschil + reden uit alliance-notulen.

"Hoeveel keer is de NH4-effluent-eis overschreden, en welke onderhouds-event ging daar aan vooraf?"

→ Correlatie sensor-trends met onderhouds-log — direct bruikbaar voor MJOP-optimalisatie.

Dit bestaat al — productie-volwassen, zodra de onderliggende data gestructureerd is.

Deel D: Wat betekent dit voor GMB?

Twee paden, twee tijdshorizonnen

Korte termijn (nu - 1 jaar)

- AI-tools voor individuele productiviteit (Copilot, ChatGPT) — gebruik onder voorwaarden
- OCR/herkenning op bestaande documenten — concrete winst
- Kritieke beslissingen altijd door een mens bevestigd

Lange termijn (1-5 jaar)

- Linked Data structuren bouwen op je belangrijkste assets
- Norm-koppelingen, eisen-objects, project-overdrachten via graph
- Dan: AI gebruiken op die structuur — betrouwbaar, traceerbaar

Kernpunt: wie nu investeert in structuur, plukt straks de vruchten van AI. Wie wacht tot "AI het oplost", blijft afhankelijk van wat externe tools toevallig doen met chaotische data.

Drie hands-on dingen om dit jaar te beginnen

1. **Aquo-conformiteit als minimum** — borg dat opleveringen Aquo-termen gebruiken. Kost niets extra, levert sectorale interoperabiliteit. Begin bij vraagspec-verwerking in Relatics.
2. **Pak één RWZI-asset-type** waar de meeste pijn zit (bv. pompputten, doseerinstallaties). Leg structuur vast: types, attributen, relaties. Een werkend prototype op Den Bosch of een opvolger — afgebakend, demonstreerbaar.
3. **Test met een AI-tool** op die gestructureerde data. Zie wat werkt en waar grenzen liggen — leer praktisch wat eisen aan datakwaliteit zijn voor AI-toepassing — bv. NH4-effluent-correlatie met onderhouds-events.

Het heeft onze warme aanbeveling om met dit drietal te beginnen. Dit is precies waar Deel 2 van deze opleiding op landt: vandaag de begrippen, in Deel 2 (optioneel) de handen aan de toetsen — met een werkende Den Bosch-deelset als use-case.

Samenvattend: vijf takeaways

1. **AI is patroonherkenning** — werkt verrassend goed, pattern-match zonder begrip of verklaring
2. **Linked Data is verbanden expliciet maken** — traceerbaar, auditeerbaar, geschikt voor contract en beheer
3. **Beide draaien om verbanden** — AI vindt ze, LD legt ze vast
4. **Garbage in, garbage out** geldt voor beide. AI versterkt slechte data — fouten worden geamplificeerd
5. **De combinatie is de winst:** LD als geheugen, AI als interface en analyse-laag

Voor morgen (Dag 2): dit verhaal terugbrengen naar concrete valkuilen in jullie eigen werkproces. Workshop 1 = waar gaat het mis, Workshop 2 = wat doe jij eraan in jouw rol.



Vragen?